



MÓDULO 8

Abordagem integrada e inovação nas DCNT

Cecília Morais

1

Visão geral do sub-módulo: modelos integrados e inovação nas DCNT

Aula	Tema	Foco	Tipo de Atividade	Avaliação
Aula 1 27.03.2026 (3h)	Modelos integrados + VBHC + medicina personalizada + gestão preditiva	Fundamentos teóricos + aplicação inicial	Atividade prática	(Organização em grupos)
Aula 2 10.04.2026 (3h)	Estudos de caso: boas práticas internacionais	Análise crítica + benchmarking	Trabalho em grupos + debate	Trabalho prático (parte 1)
Aula 3 11.04.2026 (3h)	Inovação: tecnologias digitais, IA e big data	Aplicação tecnológica + futuro da nutrição	Laboratório conceptual + simulação	Trabalho prático (parte 2)
Aula 4 17.04.2026 (3h)				Teste de avaliação (sub-módulo 1) + Finalização dos trabalhos (submódulo)

2

Competências de aprendizagem


No final do sub-módulo deverá ser capaz de:

1. **Compreender e aplicar modelos integrados de gestão das DCNT**, com foco na nutrição.
2. **Avaliar práticas internacionais** e identificar elementos transferíveis para o contexto português.
3. **Aplicar o Value-Based Health Care** à intervenção nutricional.
4. **Identificar os princípios de medicina personalizada e gestão preditiva** em planos nutricionais.
5. **Analisar e propor soluções inovadoras** usando tecnologias digitais, IA e big data.
6. **Desenvolver um trabalho prático aplicado**, com análise crítica, proposta de intervenção e fundamentação científica.

3

Aula 3: Inovação, Tecnologias Digitais, IA e Big Data

Tema: O futuro da prevenção e gestão das DCNT



Inovação: tecnologias digitais, IA e big data

4

Aula 3: Inovação, Tecnologias Digitais, IA e Big Data

Tema: O futuro da prevenção e gestão das DCNT

Que tipo de tecnologias utilizam já em contexto de trabalho ou para uso pessoal?

5

Aula 3: Inovação, Tecnologias Digitais, IA e Big Data

Tema: O futuro da prevenção e gestão das DCNT



Imagem criada com Gemini AI®

6

Aula 3: Inovação, Tecnologias Digitais, IA e Big Data

Tecnologia na Saúde e Nutrição: A Revolução Digital no Cuidado



7

Objetivos da Aula

- Compreender saúde digital
- Explorar tecnologias emergentes (IA, big data, ...)
- Relacionar IA e nutrição
- Analisar casos reais
- Criar soluções inovadoras
- Iniciar a segunda parte do trabalho final

8

1— CONTEXTUALIZAÇÃO

O que é Saúde Digital?



A saúde digital é definida como o **campo de conhecimento e prática associado ao desenvolvimento e uso de tecnologias digitais para melhorar a saúde**. Este conceito funciona como um termo abrangente que engloba a saúde eletrónica (eHealth), mas expande-a significativamente para incluir novas áreas e tecnologias.

WHO, 2025



9

1— CONTEXTUALIZAÇÃO

O que é Saúde Digital?

Telemedicina



A telemedicina expandiu-se muito após a pandemia.



mHealth



Apps permitem monitorização contínua e autogestão

Wearables



Recolhem dados valiosos para personalização.



10

O que é Saúde Digital?

A saúde digital abrange:

- Consumidores digitais e uma ampla gama de dispositivos inteligentes e equipamentos conectados.
- Tecnologias de ponta como a Internet das Coisas (*Internet of Things* - IoT), computação avançada e análise de big data.
- Inteligência artificial (incluindo aprendizagem automática), genômica e robótica.
- Soluções de cuidados virtuais e monitorização remota.

WHO, 2025

Saúde Digital**Propósito da Saúde Digital**

Fortalecer os sistemas de saúde

Capacitar:

Doentes

Profissionais de saúde

WHO, 2025

Contribuir para a visão de “saúde para todos”

1 — CONTEXTUALIZAÇÃO

**Potencial da Transformação Digital**

Melhoria dos resultados clínicos através de:

- Diagnósticos mais precisos
- Decisões terapêuticas baseadas em dados
- Terapêutica digital
- Ensaios clínicos digitais
- Apoio à autogestão do doente

Promoção de cuidados:

Centrados na pessoa
Mais eficientes e personalizados



Alinhados com VBHC

WHO, 2025

1 — CONTEXTUALIZAÇÃO

Saúde Digital**Princípios para Adoção da Saúde Digital**

- Ética
- Segurança
- Fiabilidade
- Equidade
- Sustentabilidade

WHO, 2025

Saúde Digital



Requisitos Técnicos e de Sistema

- Interoperabilidade entre sistemas
- Partilha segura de dados de saúde

Proteção da:

Privacidade

Confidencialidade dos doentes

WHO, 2025

Saúde Digital

As **WHO Digital Health Guidelines** (OMS, 2019) organizam as intervenções de saúde digital em **4 grandes tipos**, com base no público-alvo e na função no sistema de saúde:



1. Intervenções para Clientes (doentes/cidadãos)

- Direcionadas ao público em geral
- Objetivo: promover autonomia e literacia em saúde



Exemplos:

- Apps de saúde
- SMS de lembretes (consultas, medicação)
- Acesso ao registo clínico
- Telemonitorização

Saúde Digital

Tipos de Intervenções de saúde digital (cont.):

2. Intervenções para Profissionais de Saúde

Apoiam a prática clínica e tomada de decisão

Exemplos:

Sistemas de apoio à decisão clínica (CDSS)

Telemedicina

Formação digital (e-learning)

Registos clínicos eletrónicos

Saúde Digital

Tipos de Intervenções de saúde digital (cont.):

3. Intervenções para Gestores de Sistemas de Saúde

Suporte à gestão e organização dos serviços

Exemplos:

Sistemas de informação em saúde

Gestão de recursos humanos

Monitorização de desempenho

Planeamento e logística

Saúde Digital

Tipos de Intervenções de saúde digital (cont.):

4. Intervenções para Serviços de Dados em Saúde

Focadas na recolha, partilha e uso de dados

Exemplos:

Interoperabilidade entre sistemas
Big data e analytics
Vigilância epidemiológica
Registos populacionais

Saúde Digital



Saúde digital só gera valor quando:

- ✓ é confiável
- ✓ é segura
- ✓ e melhora efetivamente os cuidados e outcomes

A transformação digital só cria valor quando:

- ✓ é colaborativa
- ✓ é bem governada
- ✓ e coloca as pessoas no centro

A saúde digital não é só tecnologia —
é um ecossistema que liga:

- Doentes
- Profissionais
- Sistemas
- Dados

1 — CONTEXTUALIZAÇÃO

 Estratégia Global de Saúde Digital (OMS 2020–2027)

 Objetivo 1: Colaboração Global e Partilha de Conhecimento

Alinhar países e stakeholders a nível global

Responder conjuntamente a:

- Oportunidades
- Desafios
- Riscos da saúde digital

Promover:

- Parcerias internacionais
- Partilha de conhecimento e investimento

WHO, 2025

21

1 — CONTEXTUALIZAÇÃO

 Estratégia Global de Saúde Digital (OMS 2020–2027)

 Objetivo 2: Implementação de Estratégias Nacionais

Apoiar países no desenvolvimento de estratégias próprias

Adaptar soluções ao:

- Contexto nacional
- Recursos disponíveis

Desenvolver:

- Capacidades humanas
- Infraestruturas institucionais

Garantir uso:

- Seguro
- Escalável das tecnologias

WHO, 2025

22

1 — CONTEXTUALIZAÇÃO

 Estratégia Global de Saúde Digital (OMS 2020–2027)

 Objetivo 3: Fortalecer a Governação

Criar estruturas de governação robustas e sustentáveis

Definir normas para:

- Segurança
- Privacidade
- Interoperabilidade

Promover uso ético de:

- Dados
- Inteligência artificial
- Big data

WHO, 2025

23

1 — CONTEXTUALIZAÇÃO

 Estratégia Global de Saúde Digital (OMS 2020–2027)

 Objetivo 4: Sistemas Centrados na Pessoa

Colocar o cidadão no centro dos cuidados

Promover:

- Literacia digital em saúde
- Igualdade de género
- Empoderamento das mulheres

Evoluir de:

- Cuidados reativos → cuidados preventivos e comunitários

Garantir:

- Redução das desigualdades (não agravamento)

WHO, 2025

24

Estratégia Global de Saúde Digital (OMS 2020–2027)

Estes objetivos apoiam uma visão mais ampla de **melhorar a saúde de todos, em qualquer lugar, através da aceleração de soluções digitais centradas nas pessoas e acessíveis**, visando atingir os **Objetivos de Desenvolvimento Sustentável** e a **cobertura universal de saúde**.

O propósito fundamental é **fortalecer os sistemas de saúde, capacitando pacientes, profissionais e prestadores de serviços** através da **aplicação estratégica de tecnologias digitais**.

WHO, 2025

Desafios da Saúde Digital em Países Menos Desenvolvidos

1. Infraestrutura e Conectividade

- Falta de infraestrutura básica digital
- Acesso limitado a:
 - Internet
 - Banda larga
 - Equipamentos
- Dependência de sistemas antigos (infraestrutura legada)

2. Recursos Financeiros

Escassez de financiamento sustentável
Dificuldades em:

- Implementar
- Manter tecnologias digitais

Baixo investimento em inovação

3. Capacidade Humana e Educação

- Falta de profissionais qualificados
- Baixa literacia digital
- Necessidade de:
 - Formação técnica
 - Desenvolvimento institucional

4. Ambiente Regulatório e Governança

- Ausência de estratégias nacionais estruturadas
- Falta de apoio institucional
- Necessidade de:
 - Governança robusta
 - Planos de ação claros

WHO, 2025

1 — CONTEXTUALIZAÇÃO

 Desafios da Saúde Digital em Países Menos Desenvolvidos
 5. Normas e Segurança

Dificuldade em implementar padrões globais

Desafios em:

- Privacidade
- Segurança de dados
- Propriedade tecnológica

Risco de uso indevido de informação

 6. Fragmentação de Iniciativas

Projetos isolados (“em silos”)

Falta de integração entre sistemas

Ineficiência na prestação de cuidados

 Como ultrapassar os desafios

Promover:

- Transferência de conhecimento
- Cooperação internacional

Reforçar:

- Apoio institucional
- Estratégias nacionais

Desenvolver:

- Modelos de financiamento sustentáveis

Garantir:

- Autonomia dos países na transformação digital

WHO, 2025

27

1 — CONTEXTUALIZAÇÃO

 Estratégia Global de Saúde Digital (OMS 2020–2027)

A **inteligência artificial (IA)** é uma tecnologia de ponta com um potencial transformador para o futuro da saúde global, sendo **um dos pilares da estratégia de saúde digital** para alcançar a **cobertura universal de saúde**.

Potencial transformador de Saúde da Inteligência Artificial (IA):

1. Melhoria nos Resultados Clínicos e de Gestão - A IA tem o potencial comprovado de melhorar significativamente os resultados de saúde ao:

- **Aprimorar o diagnóstico médico** e **apoiar decisões de tratamento** baseadas em dados.
- **Impulsionar as terapêuticas digitais** e a **personalização da medicina**.
- **Otimizar a condução de ensaios clínicos digitais**, tornando-os **mais centrados na experiência do paciente** e focados em **resultados**.
- **Apoiar o autogerenciamento dos cuidados** e a **prestação de serviços centrados na pessoa**.
- Gerar **conhecimentos e competências** baseados em evidências para que profissionais de saúde prestem um apoio mais qualificado.



WHO, 2025

28

 Estratégia Global de Saúde Digital (OMS 2020–2027)

Potencial transformador de Saúde da Inteligência Artificial (IA):

2. Uso Estratégico de Dados de Saúde

- O desenvolvimento e a eficácia das soluções de IA dependem diretamente da **qualidade e do acesso aos dados**.
- **Uso secundário de dados:** A partilha de dados de saúde anonimizados é fundamental para o **teste, validação e comparação** (*benchmarking*) de soluções de IA em diferentes contextos e parâmetros.
- **Ecosistema Interoperável:** A IA beneficia-se de um ecossistema digital onde os dados podem ser trocados de forma segura entre prestadores de cuidados, gestores e pacientes.



WHO, 2025

 Estratégia Global de Saúde Digital (OMS 2020–2027)

Potencial transformador de Saúde da Inteligência Artificial (IA):

3. Governança, Ética e Segurança

Para que a transformação seja positiva, as fontes sublinham a necessidade de uma infraestrutura de governança robusta:

- **Quadros Regulatórios:** É urgente estabelecer princípios para o **uso ético dos dados** em tecnologias de IA e big data *analytics*. Isso inclui garantir a privacidade, a segurança e a proteção contra o uso inadequado de informações sensíveis.
- **Regulamentação e Certificação:** A estratégia global prevê o desenvolvimento de *frameworks* pela Organização Mundial da Saúde (OMS) para regular, avaliar e certificar dispositivos médicos baseados em IA.



WHO, 2025

1 — CONTEXTUALIZAÇÃO

 Estratégia Global de Saúde Digital (OMS 2020–2027)
Potencial transformador de Saúde da Inteligência Artificial (IA):**4. Desafios de Implementação e Capacitação**

A transformação exige investimentos que vão além da tecnologia em si:

- **Financiamento Sustentável:** A implementação e manutenção de IA e machine learning requerem modelos de financiamento sustentáveis e incentivos económicos.
- **Literacia Digital:** É necessário incluir competências de saúde digital e IA nos currículos de formação de profissionais de saúde e gestores para que possam tomar decisões informadas e utilizar as ferramentas de forma segura.
- **Inclusão:** Deve-se garantir que a introdução destas tecnologias não agrave as desigualdades existentes, promovendo uma sociedade digital inclusiva que transcenda barreiras físicas.



WHO, 2025

31

1 — CONTEXTUALIZAÇÃO

Segurança de Dados em Saúde Digital **1. Classificação dos Dados**

Dados de saúde = **dados pessoais sensíveis**

Exigem:

- Níveis elevados de proteção
- Regras mais rigorosas de segurança

 2. Enquadramento Jurídico e Regulatório

Necessidade de base legal robusta

Garantir:

- Privacidade
- Confidencialidade
- Integridade
- Disponibilidade dos dados

Inclusão de:

- Mecanismos de responsabilização
- Proteção contra ciberataques

 3. Consentimento e Transparência

Uso de dados baseado em:

- Consentimento do paciente
- Relação de confiança

Transparência sobre:

- Como os dados são utilizados
- Estratégias de segurança

 4. Direitos do Indivíduo

Direito de:

- Aceder aos próprios dados
- Saber como são tratados
- Comunicação clara e acessível

WHO, 2025

32

Segurança de Dados em Saúde Digital

5. Medidas Técnicas de Segurança

Implementação de:

- Identificação digital segura
- Autenticação e autorização

Proteção contra:

- Acesso ilegal
- Perda ou alteração de dados

Uso de:

- Auditorias
- Controlo contínuo

6. Anonimização e Uso Secundário

Para investigação ou interesse público:

- Pseudonimização
- Anonimização

Garantir:

- Proteção da identidade
- Uso ético dos dados

7. Princípio “Não Causar Dano”

Avaliar impacto das tecnologias digitais

Garantir:

- Não agravamento das desigualdades
- Respeito pelos direitos humanos
- Segurança dos pacientes

WHO, 2025

A confiança na **Saúde Digital** depende de:

- Segurança
- Transparência
- Proteção dos direitos dos cidadãos

WHO, 2025

WHO Digital Health Guidelines: Intervenções digitais recomendadas**1: Comunicação Digital**

SMS, apps

Mensagens simples podem melhorar adesão

2: Telemonitorização

Monitorização remota

Permite intervenções precoces

3: Registos Digitais

Os Registos Eletrónicos de Saúde (**EHR - Electronic Health Records**) são versões digitais e longitudinais do histórico médico de um paciente, abrangendo diagnósticos, medicamentos, resultados laboratoriais, exames de imagem, planos de tratamento e imunizações.

Ao contrário dos registos médicos eletrónicos (EMR) focados numa única visita, os EHRs fornecem uma visão abrangente e partilhável entre diferentes prestadores de cuidados de saúde.

4: IA e Algoritmos

Modelos preditivos

A IA permite prever risco e personalizar intervenções.

Oportunidades em DCNT

- Personalização
- Prevenção
- Eficiência

A tecnologia pode transformar a nutrição clínica.

Desafios em DCNT

- Privacidade
- Literacia
- Acesso


É preciso garantir equidade.

Continuous Glucose Monitoring (CGM)

A monitorização contínua da glicose (MCG) é uma tecnologia wearable que acompanha os níveis de glicose ao longo do tempo. Mede o nível de glicose no fluido intersticial logo abaixo da pele 24 horas por dia, enquanto se utiliza o dispositivo.

Um dispositivo MCG é uma ferramenta para pessoas com diabetes. Um MCG fornece informações em tempo real sobre como os níveis de glicose. Existem vários tipos de dispositivos MCG no mercado, e a tecnologia está a evoluir rapidamente. Alguns MCG ligam-se a bombas de insulina para oferecer sistemas automatizados de administração de insulina.

- Personalização da dieta
- Dados em tempo real



37

Continuous Glucose Monitoring (CGM)

O CGM permite personalizar a dieta com base na resposta glicémica.

Duas pessoas, mesma refeição → respostas diferentes

Este é o resultado central do estudo PREDICT: enorme variabilidade individual

38

2— DIGITAL HEALTH

Programa digital para DM2

O estudo avalia a eficácia e segurança de um novo modelo de cuidado contínuo para o manejo do diabetes tipo 2 (DT2) ao longo de um ano.

Metodologia: O estudo de design aberto, não randomizado e controlado, que compara dois grupos de participantes: **Intervenção de Cuidado Contínuo (CCI):** Composta por 262 adultos com DT2 que receberam suporte remoto intensivo via aplicativo. A intervenção incluiu: **Nutrição:** Abordagem metabólica de cetose nutricional, com restrição severa de HC (geralmente menos de 30g por dia) e gorduras até saciedade. **Suporte Remoto:** Acesso a uma equipa de saúde via telemedicina e monitoramento biométrico contínuo (peso, glicemia e cetonas). **Educação:** Os participantes escolheram entre aulas presenciais em grupo ou conteúdo educativo via web.

Cuidado Usual (UC): Composto por 87 adultos com DT2 que receberam o tratamento padrão de seus próprios médicos e programas de educação em diabetes.

Outcomes Primários: Alterações na hemoglobina glicada, peso corporal e uso de medicação.

Diabetes Ther (2018) 9:583–612
https://doi.org/10.1007/s13300-018-0373-9



ORIGINAL RESEARCH

Effectiveness and Safety of a Novel Care Model for the Management of Type 2 Diabetes at 1 Year: An Open-Label, Non-Randomized, Controlled Study

Sarah J. Hallberg · Amy L. McKenzie · Paul T. Williams ·

Nasir H. Bhanpuri · Anne L. Peters · Wayne W. Campbell · Tamara L. Hazbun ·

Brittanie M. Volk · James P. McCarter · Stephen D. Phinney ·

Jeff S. Volek

Received: December 28, 2017 / Published online: February 7, 2018
© The Author(s) 2018. This article is an open access publication

ABSTRACT

Introduction: Carbohydrate restriction markedly improves glycemic control in patients with type 2 diabetes (T2D) but necessitates prompt medication changes. Therefore, we assessed the effectiveness and safety of a novel care model providing continuous remote care with medication management based on biometric feedback combined with the metabolic approach of nutritional ketosis for T2D management.

Enhanced content To view enhanced content for this article go to <https://doi.org/10.6084/m9.figshare.5803119>.

Electronic supplementary material The online version of this article (<https://doi.org/10.1007/s13300-018-0373-9>) contains supplementary material, which is available to authorized users.

S. J. Hallberg · T. L. Hazbun
Medically Supervised Weight Loss, Indiana
University Health Arnett, Lafayette, IN, USA

Methods: We conducted an open-label, non-randomized, controlled, before-and-after 1-year study of this continuous care intervention (CCI) and usual care (UC). Primary outcomes were glycosylated hemoglobin (HbA_{1c}), weight, and medication use. Secondary outcomes included fasting serum glucose and insulin, HOMA-IR, blood lipids and lipoproteins, liver and kidney function markers, and high-sensitivity C-reactive protein (hsCRP).

Results: 349 adults with T2D enrolled: CCI: $n = 262$ [mean (SD): 54 (8) years, 116.5 (25.9) kg, 40.4 (8.8) kg m², 92% obese, 88% prescribed T2D medication]; UC: $n = 87$ (52 (10) years, 105.6 (22.15) kg, 36.72 (7.26) kg m², 82% obese, 87% prescribed T2D medication). 218 participants (83%) remained enrolled in the CCI at 1 year. Intention-to-treat analysis of the CCI (mean $\pm$ SE) revealed HbA_{1c} declined from

W. W. Campbell
Department of Nutrition Science, Purdue
University, West Lafayette, IN, USA

2— DIGITAL HEALTH

Programa digital para DM2

Resultados (Após 1 Ano):

Os resultados demonstraram melhorias significativas no grupo da intervenção (CCI) em comparação ao cuidado usual (UC):

Controle Glicêmico e Remissão: A HbA_{1c} média no grupo CCI caiu de 7,6% para 6,3%. Cerca de 60% dos participantes do grupo CCI alcançaram níveis de HbA_{1c} abaixo de 6,5% sem o uso de medicamentos ou utilizando apenas metformina.

Redução de Medicamentos: O uso de medicamentos para diabetes (excluindo metformina) caiu de 56,9% para 29,7% no grupo CCI.

Insulina: 94% dos usuários de insulina reduziram ou eliminaram totalmente as doses.

Sulfonilureias: Foram completamente eliminadas em todos os pacientes do grupo CCI.

Peso Corporal: Os participantes do grupo CCI perderam, em média, 13,8 kg (cerca de 12% do peso corporal total).

Marcadores Cardiovasculares e de Saúde: Houve melhorias significativas nos triglicerídeos (-24%), HDL-colesterol (+18%) e marcadores de inflamação (hsCRP -39%) e função hepática no grupo CCI.

O grupo de cuidado usual (UC) não apresentou mudanças significativas em biomarcadores ou na prescrição de medicamentos durante o período.

Segurança e Retenção: A taxa de retenção no grupo CCI foi alta (83%), e não houve eventos adversos graves atribuídos à intervenção.


2— DIGITAL HEALTH

Apps de Nutrição Baseadas em IA AI-based Dietary Assessment Tools

•Reconhecimento Alimentar por Imagem:


Foto → IA → alimento identificado

A IA consegue identificar alimentos e estimar porções com crescente precisão.



📷 1. Image-based Food Recognition

- Uso de **imagens (smartphone)** para registar refeições
- Algoritmos de IA identificam:
 - Tipo de alimento
 - Quantidade (estimada)
- Reduz dependência de memória do utilizador
- 📌 Exemplos:
 - Reconhecimento automático de pratos
 - Estimativa de porções via visão computacional



Ayswarya et al, 2026

41

2— DIGITAL HEALTH

Apps de Nutrição Baseadas em IA AI-based Dietary Assessment Tools

•Registo alimentar automático

🎤 2. Voice-based Dietary Assessment

- Registo alimentar através de **comandos de voz**
- Conversão automática em dados estruturados
- 📌 Vantagens:
 - Mais rápido
 - Menor carga para o utilizador
 - Útil para populações com baixa literacia digital

Original research article



Feasibility and usability of a voice-based dietary recall tool in older adults: A pilot comparison with ASA-24

Simone G Khandpekar¹, Rishank Singh², Caroline E Summerour³, Jim Schwoebel⁴, Xiaohui Liang⁵ and John A Batsis^{5,6}

Abstract

Objective: Dietary assessment is important for identifying patterns that can influence an older adult's medical conditions. Existing assessments are dependent on the recall limit of the current use of dietary tools. This pilot study aimed to compare the short-term usability and acceptability of a novel voice-based dietary recall tool (DataBoard) to the traditional Automated Self-Administered Dietary Assessment Tool (ASA-24) in older adults.

Methods: Participants aged over 65 years old, meeting specific criteria, were recruited through Research For Me and Research Match across a six-month period in 2023–2024. During the session on Zoom, they were randomly assigned to complete either a voice-based recall via DataBoard or use ASA-24 first, followed by a semi-structured interview. DataBoard enables survey completion using speech input through shared links. We obtained data on meal choices, participant feedback, and preferences for either method using a 1–10 rating scale (low to high agreement). Descriptive statistics and qualitative coding were conducted.

Results: We recruited 20 participants (mean age 70.5 ± 4.26 years, 55% female and 35% non-White). Feasibility and acceptability of DataBoard's voice-based recall were rated as 7.95/10 and 7.6/10. Participants rated the overall performance of DataBoard as easier than the ASA-24, with an average rating of 6.7/10. Participants preferred using DataBoard; they felt it could be used more frequently to report food than ASA-24 (mean 7.2/10). Dedoose analysis revealed preferences, challenges, and usability insights for DataBoard.

Conclusion: Older adults supported voice-based recall as a means to evaluate dietary intake. Further evaluation with larger cohorts of older adults could provide additional opportunities to create a better tool for food recall.

Keywords

Voice-based recall, dietary assessment, older adults, digital health tool, nutrition surveillance

Received: 1 July 2025; accepted: 17 October 2025

Ayswarya et al, 2026

42

Apps de Nutrição Baseadas em IA *AI-based Dietary Assessment Tools*

- Algoritmos Preditivos

3. Machine Learning–based Pattern Recognition

Algoritmos aprendem padrões alimentares

Identificam:

- Hábitos
- Tendências
- Riscos nutricionais

Aplicação:

Personalização de recomendações
Previsão de comportamentos alimentares




Figura 79 - Aplicação com o feedback das duas refeições

Visão computacional para detecção de hábitos alimentares – Antelo A, 2022
Ayswarya et al, 2026

43

Apps de Nutrição Baseadas em IA *AI-based Dietary Assessment Tools*

- Aplicações móveis com IA


4. Mobile Apps com IA integrada

Plataformas digitais que combinam:

- Registo alimentar
- Feedback em tempo real
- Coaching nutricional

Funcionalidades:

Sugestões automáticas
Alertas nutricionais
Monitorização contínua



Ayswarya et al, 2026

44

2— DIGITAL HEALTH

Apps de Nutrição com IA

Exemplos: **Yazio**, MyFitnessPal AI, ZOE Health


Comentários:

“As recomendações nutricionais, embora práticas, não substituem um acompanhamento personalizado por um profissional de saúde.

Além disso, as avaliações de alimentos podem por vezes levar a uma sobrestimação ou subestimação das ingestões.

Por fim, a aplicação destaca o jejum intermitente, sem especificar nem a sua utilidade nem as contraindicações e sem que eu o tenha previamente selecionado.

A aplicação pode não ser adaptada a pessoas vulneráveis como adolescentes, mulheres grávidas ou pessoas com perturbações alimentares.”




45

2— DIGITAL HEALTH

Apps de Nutrição com IA

Exemplos: Yazio, **MyFitnessPal AI**, ZOE Health

O MyFitnessPal integrou funcionalidades com inteligência artificial, principalmente a **Refeição Digitalizada** e a **Análise de Fotografias**, para simplificar o rastreio de calorias, permitindo aos utilizadores digitalizar os alimentos com a câmara ou carregar fotografias para um registo nutricional instantâneo e automático. Estas ferramentas premium foram concebidas para identificar os ingredientes, estimar o tamanho das porções e registar as refeições rapidamente, de forma a melhorar a precisão do rastreio.




46

2— DIGITAL HEALTH

Apps de Nutrição com IA

Exemplos: Yazio, MyFitnessPal AI, **ZOE Health**

O aplicativo ZOE Health é uma plataforma focada em nutrição personalizada e saúde intestinal, baseada em ciência, que utiliza inteligência artificial para ajudar os usuários a melhorar a alimentação, energia, sono e humor, o que pode resultar em perda de peso como consequência de hábitos mais saudáveis.



Recursos do ZOE Health:

- **Scanner de IA de Alimentos:** Permite tirar fotos das refeições para receber pontuações de saúde instantâneas e feedback nutricional personalizado.
- **Pontuação Alimentar Baseada em Dados:** ZOE utiliza dados do microbioma e estudos nutricionais para dar pontuações que ajudam a escolher alimentos melhores para o seu corpo.
- **Foco na Saúde Intestinal:** O programa aborda como o microbioma intestinal influencia a saúde geral e a gestão de peso.
- **Abordagem Educacional:** O objetivo é ensinar a comer melhor, em vez de focar apenas na restrição calórica, visando reduzir alimentos ultraprocessados e aumentar o consumo de fibras e proteínas.

47

2— DIGITAL HEALTH

Apps de Nutrição Baseadas em IA *AI-based Dietary Assessment Tools*

• Registo alimentar automático

5. Automated Dietary Recall (24h recall digital) Versões automatizadas do recordatório alimentar 24h


Guiadas por IA (chatbots ou interfaces inteligentes)

✳ Benefícios:

Maior padronização

Redução de erros humanos

Escalabilidade em estudos populacionais




Ayswarya et al, 2026

48

Apps de Nutrição Baseadas em IA

AI-based Dietary Assessment Tools

•Wearables e outros dispositivos móveis



6. Wearables e sensores

Integração com dispositivos:

- Smartwatches
- Sensores fisiológicos
- Estimativa indireta de ingestão alimentar

Wearables: O que Medem?

- Atividade física
- Sono
- Frequência cardíaca
- HRV (Heart Rate Variability, ou “Variabilidade da Frequência Cardíaca”)

Exemplo:

Correlação entre atividade, metabolismo e ingestão

Sono → fome

Stress → escolhas alimentares

Atividade → necessidades energéticas

A nutrição não existe isolada — wearables ajudam a integrar fatores.

Ayswarya et al, 2026

Apps de Nutrição Baseadas em IA

Table 1 Summary of studies included in the review.

AI-DA tool/system	Study design	Comparator	Population studied	Key findings	Reference
Im2Calories	Validation study	Weighed food records	Adults (controlled settings)	Food recognition accuracy 70%-90%; reduced accuracy for mixed dishes	Meyers et al. (2015) ⁸
Deep-learning food recognition models	Validation study	Dietitian-coded records	Adults	Up to 95% accuracy for single-item foods; lower accuracy for mixed dishes	Ahmad et al. (2016) ¹⁸
Image-based AI systems (Food-101)	Dataset benchmarking	Manual labeling	General food images	Classification accuracy 70%-95% depending on food complexity	Tripathi (2021) ⁹
Mobile Food Record (mFR)	Free-living feasibility study	Traditional food diaries	Free-living adults	>90% compliance; improved data completeness	Kerr et al. (2016) ¹⁹
Image-based dietary assessment	Free-living validation	Dietitian-coded records	Free-living adults	80%-90% food identification accuracy; portion errors 18%-22%	Gemming et al. (2015) ¹⁷
Portion-size estimation systems	Validation study	Weighed food records	Adults (lab and free-living)	Portion-size error 10%-25%; higher error in free-living settings	Fang et al. (2020); Tahir and Loo (2021) ^{14,15}
NLP-assisted ASA24	Method evaluation	Interviewer-led 24-h recall	Adults	40% reduction in interviewer burden; improved consistency	Fulgioni et al. (2020) ¹⁶
Wearable bite-detection sensors	Validation study	Observed eating events	Adults	82% accuracy for bite detection	Lo et al. (2024) ¹⁷
Wearable camera systems	Field validation study	Dietitian review	African populations	High feasibility and acceptability	Lo et al. (2024) ¹⁷
Multimodal AI nutrition systems	Comparative evaluation	Image-only systems	Adults	12%-20% improvement in nutrient estimation accuracy	Zhu et al. (2022) ²⁰
FoodLens	Intervention study (12 weeks)	Standard care	Adults with diabetes	HbA1c reduction of 0.6%-0.8%; improved adherence	Han et al. (2023) ²¹
Bite.AI/DietLens	Intervention study	Self-reported food diaries	Adults with obesity/CVD	20%-35% improvement in dietary compliance	Panayotova (2025) ²²
NutriTrack-CKD	Clinical intervention study	Standard renal dietary care	CKD patients	Reduced serum potassium; improved dietary adherence	Palomares et al. (2025) ²³
DayTwo/ZOE	Precision nutrition studies	Standard dietary advice	Adults	20%-25% reduction in postprandial glucose responses	Zeevi et al. (2015); Pammi et al. (2024) ^{24,25}

Ayswarya et al, 2026

Apps de Nutrição Baseadas em IA

The introduction of smartwatches over the last few years has made widely available a new type of wearable, everyday-usage device that is equipped with dozens of sensors. The sensors embedded in the smartwatch constitute a valuable source of data about the bodily functions of the smartwatch user; a source that has already been exploited for inferring information concerning the human behavior. One possible application of the aforementioned information inference is the prediction of eating-related events, such as bite instances. Accurate bite instance prediction from smartwatch sensors could serve as a trigger for appropriate user feedback in the context of just-in-time adaptive interventions for eating behavior management. In this paper, we present a novel method for real-time detection of bite instances from 3-axis orientation data acquired by a smartwatch. The evaluation of the proposed method has been performed on eight annotated orientation timeseries, generated by eight individuals who wore a commercial smartwatch on their active hand while eating a bowl of milk with cereals. Both the classification accuracy of the method and its ability to make realtime decisions were evaluated, yielding very promising results.




Figure 2. Photograph taken from one video of the experiment to demonstrate the experimental setup.

Real-time Bite Detection from Smartwatch Orientation Sensor Data, Maramis 2016

51

Apps de Nutrição Baseadas em IA

AI-Powered Diet Tracker for Kidney Health

Track potassium, phosphorus, sodium and protein in seconds — just take a photo. Designed for CKD patients, validated against KDIGO guidelines.

[Start for Free →](#) [See How It Works](#)

NHS DCB0129 Compliant WCAG 2.1 AA FHIR R4


52

Apps de Nutrição Baseadas em IA**Vantagens principais**

- Redução de viés de memória
- Maior precisão na recolha de dados
- Monitorização em tempo real
- Escalabilidade para grandes populações

Limitações

- Dificuldade na estimativa de porções
- Erros no reconhecimento de alimentos
- Dependência de tecnologia
- Questões de privacidade de dados



Ayswarya et al, 2026

53

Apps de Nutrição Baseadas em IA**Applications in Clinical Nutrition****Avaliação nutricional**

Monitorização mais precisa da ingestão alimentar
 Redução de erros de autorrelato
 Suporte à prática clínica

Nutrição personalizada


Recomendações ajustadas ao perfil individual
 Integração de:
 Dados clínicos
 Comportamento alimentar
 Apoio à medicina personalizada

Gestão de doenças (DCNT)

Aplicação em:
 Diabetes
 Obesidade
 Doenças cardiovasculares
 Monitorização contínua e feedback em tempo real

Apoio à adesão terapêutica

Alertas e lembretes
 Coaching digital
 Maior engagement do doente



Ayswarya et al, 2026

54

Apps de Nutrição Baseadas em IA **Applications in Public Health Nutrition** **Vigilância alimentar**


Recolha de dados em larga escala
Monitorização de padrões alimentares populacionais

 Investigação epidemiológica

Dados mais detalhados e em tempo real
Estudos mais robustos e escaláveis

 Intervenções populacionais

Programas de promoção da saúde
Avaliação de políticas alimentares

 **Saúde digital e VBHC**

- Medição de outcomes reais
- Apoio à tomada de decisão em políticas públicas

Ayswarya et al, 2026

55

Apps de Nutrição Baseadas em IA **Challenges and Future Directions** **Precisão e validação**

Necessidade de validação científica rigorosa
Limitações na estimativa de porções
Variabilidade na qualidade dos algoritmos

 Complexidade alimentar

Dificuldade em:
Identificar alimentos mistos
Avaliar receitas complexas

 Privacidade e ética

- Proteção de dados pessoais
- Consentimento informado
- Uso ético da informação

 Acessibilidade e equidade


- Desigualdade no acesso à tecnologia
- Risco de exclusão digital

 Integração no sistema de saúde

- Necessidade de integração com:
 - Registos clínicos
 - Fluxos de trabalho clínico
- Resistência à adoção

 Sustentabilidade e implementação

Escalabilidade dos modelos
Custos de implementação
Manutenção tecnológica



Ayswarya et al, 2026

56

Integração de Dados Ômicos e Biomarcadores

As ferramentas digitais estão a começar a integrar dados complexos para personalizar a nutrição de precisão:

Genômica: Plataformas como 23andMe e DNAfit **fornece planos de dieta e exercício** baseados no perfil genético do utilizador (ex: variantes dos genes FTO ou MC4R).

Microbiômica: Ferramentas como Viome utilizam a sequenciação do microbioma (16S rRNA) para sugerir planos de refeições que apoiam a saúde intestinal.

Metabolômica e Monitorização de Glucose: O uso de Monitores Contínuos de Glucose (CGM), integrados com apps e wearables, permite ajustar a dieta com base na resposta glicêmica em tempo real

Integração de Dados Ômicos e Biomarcadores

A integração destas tecnologias num **quadro de gestão de peso de precisão** permite traduzir dados biológicos em intervenções práticas, embora ainda existam desafios quanto ao custo, acessibilidade e privacidade dos dados.

Table 1. Representative Technologies in Precision Weight Management.

Technology Type	Representative Tools	Intervention Form	Advantages	Limitations	References
Genomics	23andMe, DNAfit (✓)	Personalized diet and exercise plans	Individualized guidance	High cost; limited generalizability across populations	[83]
Metabolomics	Serum profiling (△)	Nutrition adjustment	Real-time feedback	Laboratory-dependent; low accessibility in remote areas	[84]
Microbiomics	Viome, 16S rRNA (△)	Probiotic/ dietary adjustment	Improves gut health	Expensive; complex interpretation; limited standardization	[85]
Digital Tools	MyFitnessPal, wearables (✓)	Self-tracking, coaching	Boosts adherence	Digital divide; limited access in low-income populations	[79]

Note: Symbols indicate the level of integration into digital health tools: ✓ = already integrated; △ = partially integrated or under development.

Inteligência Artificial (IA) e Big Data

A IA atua como o motor de recomendação central que processa os dados de múltiplas fontes.

Análise Preditiva: Algoritmos analisam padrões dietéticos e perfis metabólicos para gerar planos de refeições altamente específicos (ex: dietas de baixo índice glicêmico para quem tem resistência à insulina).

Feedback Dinâmico: Sistemas de coaching inteligente utilizam IA para fornecer orientações automatizadas e sustentáveis sobre estilo de vida.

Table 2. Summary of Recent Clinical Studies Applying Digital Tools in Obesity Management.

Design & Sample	Intervention	Duration	Main Findings	References
RCT; N = 150 adults with obesity (BMI ≥ 30)	Multimodal app ("zanadio") (✓)	12 months	Mean weight loss 7.75% (95% CI -9.66 to -5.84); improvements in waist-to-height ratio and QoL.	[95]
RCT; N = 168 adults with BMI 30–40	Multimodal app (ADHOC) vs. delayed access (✓)	12 weeks + 12-week follow-up	Greater short-term weight reduction and improved dietary intake and QoL.	[96]
Systematic review and component network meta-analysis; includes 68 RCTs	Digital support features across weight-loss apps (✓)	Up to 12 months	Identified key components (education; specialist contact) associated with weight loss (-2.52 kg at 6 months; -2.11 kg at 12 months).	[80]
Umbrella review; 507 RCTs (N ≈ 206,873)	Digital health (apps, wearables, and SMS) (✓)	Mostly 3–6 months	Modest but significant improvements: weight (-1.89 kg), steps/day (+1329), sedentary behavior, and energy intake (-103 kcal/day).	[97]
Cohort study; N = 46,579 adults	Wearables vs. pedometer apps (✓)	12–24 weeks	Wearable users showed higher physical activity, improved diet, and reduced metabolic syndrome risk.	[81]
Observational real-world study; N = 2217 CGM users	CGM + wearables + app-based coaching (✓)	28 days	Reduced caloric intake, increased activity, and improved glycemic and metabolic outcomes.	[82]

BMI: body mass index; RCT: randomized controlled trial; CI: confidence interval; QoL: quality of life; SMS: short message service; CGM: continuous glucose monitoring. Note: Symbols indicate the level of integration into digital health tools: ✓ = already integrated.

Liu et al, 2025

Combinação de métodos

•Evolving Neural Networks for Continuous Blood Glucose Forecasting


A neuroevolução é uma **técnica de inteligência artificial** que combina **redes neurais artificiais** com **algoritmos evolutivos** (inspirados na seleção natural) para otimizar, treinar ou estruturar sistemas inteligentes.

Este estudo apresenta um **método inovador de neuroevolução** concebido para prever os níveis de glicose no sangue em pacientes com diabetes. Através da **utilização de algoritmos genéticos** para otimizar os pesos de uma rede neuronal, a investigação conseguiu **superar a precisão das técnicas tradicionais** de retropropagação. O modelo foca-se na análise de dados provenientes de **dispositivos de monitorização contínua (CGM)**, permitindo **antecipar variações perigosas em apenas cinco minutos**. Esta abordagem personalizada visa mitigar complicações de saúde graves ao lidar com a complexidade de fatores como a alimentação e o exercício físico. Os resultados demonstram que **a rede evoluída** obteve um **erro significativamente menor, utilizando uma janela de dados mais reduzida para realizar as suas previsões**. Em última análise, esta tecnologia representa um avanço importante na automação do controlo glicémico e na melhoria da qualidade de vida dos doentes.

61

Combinação de métodos

•Evolving Neural Networks for Continuous Blood Glucose Forecasting



62

Big Data em Saúde Pública

O que é Big Data?

Consiste em **extensos conjuntos de dados** caracterizados principalmente pelo seu **volume, variedade, velocidade e/ou variabilidade**. Estes dados exigem uma arquitetura escalável para armazenamento, manipulação e análise eficientes.

Big Data no Cuidado de Saúde (Healthcare)

No cuidado de saúde específico para o paciente, o Big Data tem permitido escalas sem precedentes de:

- Volume: Aumentou significativamente em áreas como a genômica, investigação molecular e mineração de imagens médicas.
- Variedade: Permite integrar dados de diversas fontes, como a qualidade do ar, dispositivos vestíveis (wearables), conteúdos gerados por pacientes na web e movimentos de médicos ou pacientes.
- Velocidade: Possibilitou avanços na predição clínica e diagnósticos em tempo real.

Big Data em Saúde Pública

Big Data na Saúde Pública de Precisão (Precision Public Health)

A saúde pública de precisão é definida como a **utilização de tecnologias e métodos emergentes para descrever e analisar indivíduos e grupos populacionais** de forma mais precisa, **visando melhorar a saúde geral das populações**.

O Big Data é um pilar fundamental desta prática, pois **permite prever e compreender riscos de saúde** de forma granular e personalizar tratamentos para subpopulações específicas e homogêneas.

- Vigilância nutricional
- Modelos populacionais
- Previsão de tendências

Big Data em Saúde Pública

Vigilância de Doenças e Detecção de Sinais (Disease Surveillance and Signal Detection)

Uma das utilizações mais revolucionárias do Big Data. A sua utilidade manifesta-se em:

- **Monitorização em tempo real:** Permite rastrear surtos de doenças como cólera, dengue, Ébola, HIV e Zika.
- **Rastreo de movimentos:** Utiliza dados de telemóveis, viagens aéreas, GPS e redes sociais (como o Twitter) para monitorizar o movimento humano, que é um componente crítico na transmissão de patógenos.
- **Detecção de sinais precisos:** Tem mostrado eficácia na monitorização da resistência a antibióticos, poluição do ar e segurança de medicamentos.

Big Data em Saúde Pública

Previsão de Risco (Predicting Risk)

Utilizado para desenvolver modelos que preveem a propagação de doenças ou resultados de saúde futuros, permitindo intervenções preventivas.

Exemplos:

- Modelos preditivos: Previsão de risco para poluição do ar, diabetes, abuso infantil, progressão do tabagismo e surtos de vírus como o Zika ou o Nilo Ocidental.
- Integração de fontes: Combinação de dados de redes sociais e internet com fontes tradicionais para evitar falhas de modelos anteriores e aumentar a precisão

Direcionamento de Intervenções (Targeting Interventions)


Permite **identificar subgrupos homogêneos** dentro de uma **população heterogênea** para aplicar intervenções mais eficazes.

- **Intervenções estratificadas:** Utilizado na identificação de tratamentos específicos para asma infantil, obesidade, uso de drogas injetáveis e malária

2 — DIGITAL HEALTH

Digitalização nos Sistemas de Saúde Internacionais

NHS: National Health Service = sistema público de saúde do Reino Unido.



O NHS AI Lab (**Laboratório de Inteligência Artificial do NHS**) foi criado em 2019 com um investimento inicial de £143,5 milhões para acelerar a adoção segura e ética de tecnologias de IA no sistema de saúde de Inglaterra.

Gerido pela NHS England Digital, o laboratório funciona como um centro de coordenação entre o governo, o setor da saúde, a academia e empresas tecnológicas.

67

3 — ATIVIDADE PRÁTICA

Atividade Prática (para avaliação – Parte 2)

Criar uma solução inovadora para uma DCNT usando:

IA
Big data
Ferramentas digitais
Personalização nutricional

68

3 — ATIVIDADE PRÁTICA

Estrutura da Proposta

- 1.Problema
- 2.População-alvo
- 3.Solução digital
- 4.Modelo de valor (VBHC)
- 5.Indicadores
- 6.Riscos

Exemplos de Problemas**Conteúdo:**

- Baixa adesão alimentar
- Pré-diabetes
- Obesidade infantil
- Falta de monitorização

Definir a População-Alvo

Idade, risco, contexto

Criar a Solução

Exemplos:

- App com IA
- Plataforma digital
- Wearable nutricional
- Programa híbrido



69

3 — ATIVIDADE PRÁTICA

Estrutura da Proposta

- 1.Problema
- 2.População-alvo
- 3.Solução digital
- 4.Modelo de valor (VBHC)
- 5.Indicadores
- 6.Riscos

Modelo de Valor (VBHC)

Outcomes / Custos

Outcomes a Considerar

Clínicos
PROMs
PREMs

Indicadores de Sucesso

Exemplos:

- ↓ HbA1c
- ↓ peso
- ↑ adesão
- ↑ satisfação



70

3 — ATIVIDADE PRÁTICA

Estrutura da Proposta

1. Problema
2. População-alvo
3. Solução digital
4. Modelo de valor (VBHC)
5. Indicadores
6. Riscos

Análise de Riscos

- Privacidade
- Literacia digital
- Acesso

Mitigação de Riscos

Encriptação
Interface simples
Coaching híbrido



71

Intervenções VBHC nas diferentes áreas das DCNTs

Área	Intervenções VBHC possíveis	Outcomes relevantes (clínicos, PROMs, PREMs)	Exemplos de aplicação
Nutrição na Gestão Integrada das DCNT	- Planos nutricionais integrados em equipas multidisciplinares - Monitorização contínua de outcomes - Protocolos baseados em evidência - Educação terapêutica estruturada	HbA1c, PA, LDL, peso, adesão, qualidade de vida	Programas integrados de DM2 com nutricionista + médico + psicólogo; dashboards de outcomes
Doenças Cardiovasculares	- Intervenções nutricionais centradas em risco absoluto - Programas de redução de sal e gordura saturada - Reabilitação cardíaca com componente nutricional	LDL, PA, hs-CRP, SCORE2, capacidade funcional	Programa VBHC para pós-enfarte com metas nutricionais e monitorização
Gestão do Peso e Obesidade	- Programas estruturados com metas mensuráveis - Coaching nutricional contínuo - Intervenções comportamentais integradas	% perda de peso, circunferência abdominal, saciedade, energia	Programa de 12 semanas com metas VBHC e acompanhamento híbrido
Nutrição na Diabetes	- Personalização alimentar baseada em glicemia - Educação alimentar estruturada - Monitorização digital	HbA1c, glicemia pós-prandial, peso, adesão	Programa de DM2 com CGM + plano alimentar personalizado
Doença Renal	- Intervenções nutricionais para retardar progressão - Gestão de fósforo, potássio e proteína - Educação alimentar para diálise	Taxa de progressão (eGFR), fósforo, potássio, albumina	Programa VBHC para DRC com metas nutricionais individualizadas
Doenças Oncológicas	- Suporte nutricional precoce - Prevenção de perda de massa magra - Gestão de sintomas alimentares	Peso, massa magra, ingestão, fadiga, náuseas	Programa de suporte nutricional integrado em oncologia
DCNT ao Longo do Ciclo de Vida	- Intervenções adaptadas a idade/etapas - Prevenção precoce - Educação alimentar familiar	Crescimento, IMC, hábitos alimentares, literacia	Programa de prevenção de obesidade infantil com VBHC

72

Aplicações de Big Data / IA / Inovação nas diferentes áreas

Módulo	Aplicações de Big Data / IA	Oportunidades	Exemplos práticos
Nutrição na Gestão Integrada das DCNT	• Dashboards integrados • Modelos preditivos de risco • IA para segmentação de doentes	Melhorar gestão populacional e personalização	Plataforma que identifica doentes com risco de descompensação
Doenças Cardiovasculares	• IA para previsão de eventos CV • Análise de padrões alimentares • Wearables (PA, FC, HRV)	Prevenção secundária e primária	Algoritmo que ajusta plano alimentar com base em HRV
Gestão do Peso e Obesidade	• Apps com IA para registo alimentar • Modelos de predição de perda de peso • Chatbots comportamentais	Aumentar adesão e personalização	App que prevê resposta a diferentes padrões alimentares
Nutrição na Diabetes	• CGM + IA para prever resposta glicémica • Algoritmos de personalização alimentar • Alertas preditivos	Personalização extrema da dieta	Sistema tipo PREDICT adaptado à prática clínica
Doença Renal	• Modelos preditivos de progressão da DRC • IA para controlo de fósforo/potássio • Monitorização remota	Prevenção da progressão e complicações	Algoritmo que ajusta ingestão proteica e eletrólitos
Doenças Oncológicas	• IA para previsão de caquexia • Análise de ingestão via imagem • Monitorização remota de sintomas	Intervenção precoce e suporte nutricional	App que identifica risco de perda de massa magra
DCNT ao Longo do Ciclo de Vida	• Big data para vigilância nutricional • IA para padrões alimentares familiares • Apps educativas gamificadas	Prevenção precoce e educação	App gamificada para hábitos alimentares saudáveis em crianças

73

4 — CONCLUSÕES



- A nutrição é central
- A tecnologia é aceleradora
- O futuro é personalizado e preditivo



74

Global strategy on digital health 2020-2027. Geneva: World Health Organization; 2025. Licence: CC BY-NC-SA 3.0 IGO

Hallberg SJ, McKenzie AL, Williams PT, Bhanpuri NH, Peters AL, Campbell WW, Hazbun TL, Volk BM, McCarter JP, Phinney SD, Volek JS. Effectiveness and Safety of a Novel Care Model for the Management of Type 2 Diabetes at 1 Year: An Open-Label, Non-Randomized, Controlled Study. *Diabetes Ther.* 2018 Apr;9(2):583-612. doi: 10.1007/s13300-018-0373-9. Epub 2018 Feb 7. Erratum in: *Diabetes Ther.* 2018 Apr;9(2):613-621. doi: 10.1007/s13300-018-0386-4. PMID: 29417495; PMCID: PMC6104272.

Vaughan, N. Continuous blood glucose monitoring prediction for diabetes using evolving neural network. *Sci Rep* **15**, 45292 (2025). <https://doi.org/10.1038/s41598-025-29169-x>

Ayswarya M.N., Sheba Sangeetha Jeyaraj, Artificial intelligence in dietary assessment: a narrative review, *Global Perspectives on Nutrition*, Volume 1, Issue 1, January 2026, woag001, <https://doi.org/10.1093/gpnutr/woag001>

Liu X, Xu M, Wang H, Zhu L. Integrating Precision Medicine and Digital Health in Personalized Weight Management: The Central Role of Nutrition. *Nutrients.* 2025 Aug 20;17(16):2695. doi: 10.3390/nu17162695. PMID: 40871725; PMCID: PMC12389408.

Dolley S. Big Data's Role in Precision Public Health. *Front Public Health.* 2018 Mar 7;6:68. doi: 10.3389/fpubh.2018.00068. PMID: 29594091; PMCID: PMC5859342.